

# Regresión lineal univariada y multivariada. Parte 3

Pontificia Universidad Javeriana  
Francisco Carlos Calderon Ph.D  
2020

# Objetivos

A partir del procedimiento hallado para una regresión de una variable, realizar el mismo procedimiento para varias variables.

Introducción al pre-procesamiento de las características y la iteración de variables de configuración (alpha)

# Replantando

$$h_{\theta}(x) = \theta_0 + \theta_1 x = y$$

$$\min_{\theta_0, \theta_1} \frac{1}{2n} \sum_{i=1}^n (h_{\theta}(x^{(i)}) - y^{(i)})^2 = \min_{\theta_0, \theta_1} J(\theta_0, \theta_1)$$

$$h_{\theta}(\mathbf{x}) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_3 + \cdots + \theta_m x_m$$

$$\min_{\theta_0, \theta_1, \dots, \theta_m} J(\theta_0, \theta_1, \dots, \theta_m)$$

$$\min_{\theta_0, \theta_1, \dots, \theta_m} \frac{1}{2n} \sum_{i=1}^n (h_{\theta}(\mathbf{x}^{(i)}) - y^{(i)})^2$$

# Descenso del gradiente multivariado

Minimizar:

$$\min_{\theta_0, \theta_1} J(\theta_0, \theta_1)$$

Repetir hasta encontrar convergencia:

$$\theta_j^{(k+1)} = \theta_j^{(k)} - \alpha \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1)$$

Minimizar:

$$\min_{\theta_0, \theta_1, \dots, \theta_m} J(\theta_0, \theta_1, \dots, \theta_m)$$

Repetir hasta encontrar convergencia:

$$\theta_j^{(k+1)} = \theta_j^{(k)} - \alpha \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1, \dots, \theta_m)$$

**Para el caso multivariado:**  $h_{\theta}(\mathbf{x}) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_3 + \dots + \theta_m x_m$

$$\min_{\theta_0, \theta_1, \dots, \theta_m} \frac{1}{2n} \sum_{i=1}^n (h_{\theta}(\mathbf{x}^{(i)}) - y^{(i)})^2$$

$$\theta_0^{(k+1)} = \theta_0^{(k)} - \alpha \frac{\partial}{\partial \theta_0} J(\theta_0^{(k)}, \theta_1^{(k)}, \dots, \theta_m^{(k)})$$

$$\theta_1^{(k+1)} = \theta_1^{(k)} - \alpha \frac{\partial}{\partial \theta_1} J(\theta_0^{(k)}, \theta_1^{(k)}, \dots, \theta_m^{(k)})$$

$$\theta_2^{(k+1)} = \theta_2^{(k)} - \alpha \frac{\partial}{\partial \theta_2} J(\theta_0^{(k)}, \theta_1^{(k)}, \dots, \theta_m^{(k)})$$

Resolver ustedes mismos!

▪  
▪  
▪

# Para el caso multivariado:

$$h_{\theta}(\mathbf{x}) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_3 + \cdots + \theta_m x_m$$

$$\min_{\theta_0, \theta_1, \dots, \theta_m} \frac{1}{2n} \sum_{i=1}^n (h_{\theta}(\mathbf{x}^{(i)}) - y^{(i)})^2$$

$$\theta_0^{(k+1)} = \theta_0^{(k)} - \alpha \frac{1}{n} \sum_{i=1}^n (h_{\theta^k}(\mathbf{x}^{(i)}) - y^{(i)})$$


$$\theta_1^{(k+1)} = \theta_1^{(k)} - \alpha \frac{1}{n} \sum_{i=1}^n (h_{\theta^k}(\mathbf{x}^{(i)}) - y^{(i)}) x_1^{(i)}$$

$$\theta_2^{(k+1)} = \theta_2^{(k)} - \alpha \frac{1}{n} \sum_{i=1}^n (h_{\theta^k}(\mathbf{x}^{(i)}) - y^{(i)}) x_2^{(i)}$$

$$\theta_m^{(k+1)} = \theta_m^{(k)} - \alpha \frac{1}{n} \sum_{i=1}^n (h_{\theta^k}(\mathbf{x}^{(i)}) - y^{(i)}) x_m^{(i)}$$

# Pre procesamiento de características


Ya teniendo resuelta la  
regresión lineal  
Caso ideal



# Pre procesamiento de características

IDEA:

Pre procesar para mejorar la convergencia de los métodos de optimización.




Ambos gradientes son afectados por el mismo  $\alpha$

- O uso alphas diferentes, -> no tan buena idea!
- O hago que mis características "x" sean similares. -> al parecer es una mejor idea!
  - Con esto también logro que mis x sean todos igual de importantes.



# Normalización de características.

La normalización se hace necesaria ya que al tener características en intervalos similares se facilita la convergencia de los algoritmos de optimización.



j=	Voltaje	Corriente
0	1	0.16961027
1	1.5	0.28339581
2	2	0.38635874
3	2.5	0.47022787
4	3	0.43328129
5	3.5	0.60026765
6	4	0.73833898
7	4.5	0.79031502
8	5	0.87746427
9	5.5	0.84356446
10	6	0.96443892
Promedio	3.5	0.59611484
Desviación	1.58113883	0.25227499

# Cómo normalizar?

A partir de la estadística si se supone una distribución


$$x' = \frac{x - \bar{x}}{\sigma}$$

Tomando el máximo y el mínimo  
“min-max”

$$x' = \frac{x - \min(x)}{\max(x) - \min(x)}$$

Centrando en la media

$$x' = \frac{x - \text{average}(x)}{\max(x) - \min(x)}$$




[https://en.wikipedia.org/wiki/Feature\\_scaling](https://en.wikipedia.org/wiki/Feature_scaling)

<https://www.youtube.com/watch?v=9ONRMymR2Eg>

# Normalización de características.

Gráfico de Voltaje contra corriente

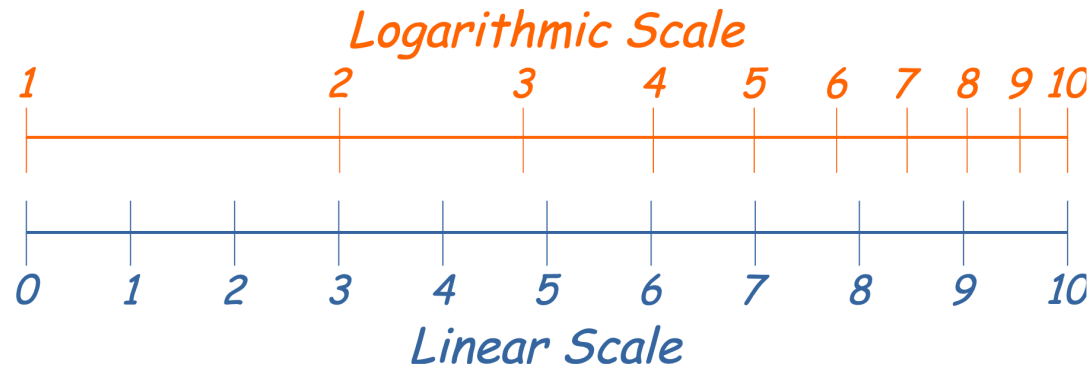


Voltaje Normalizado	Corriente
-1.58113883	0.16961027
-1.264911064	0.28339581
-0.948683298	0.38635874
-0.632455532	0.47022787
-0.316227766	0.43328129
0	0.60026765
0.316227766	0.73833898
0.632455532	0.79031502
0.948683298	0.87746427
1.264911064	0.84356446
1.58113883	0.96443892

Para este caso normalizamos restando el promedio de las muestras y dividiendo la resta por una desviación estándar

Promedio	3.5	0.59611484
Desviación	1.58113883	0.25227499

# Selección del alpha



En la práctica es común tener que iterar entre diferentes alphas si no se logra una convergencia rápida o diverge.

# Ejercicio en clase:

1. Normalizar  $x$ .
2. Encontrar el mínimo para  $J$  y verificar.
3. Encontrar un buen valor para  $\alpha$
4. Desnormalizar datos
5. Predecir usando nuestro regresor

6. Hacer caso multivariado  
Probar con nuevos datos multivariados:  
Ver excel adjunto hojas 3 y 4